DOI: 10.13334/j.0258-8013.pcsee.211150 文章编号: 0258-8013 (2022) 05-1837-15 中图分类号: TM 91 文献标识码: A

基于 PSO 算法的电动汽车有序充放电 两阶段优化策略

张良, 孙成龙*, 蔡国伟, 黄南天, 吕玲

(现代电力系统仿真控制与绿色电能新技术教育部重点实验室(东北电力大学), 吉林省 吉林市 132012)

Two-stage Optimization Strategy for Coordinated Charging and Discharging of EVs Based on PSO Algorithm

ZHANG Liang, SUN Chenglong*, CAI Guowei, HUANG Nantian, LYU Ling

(Key Laboratory of Modern Power System Simulation and Control & Renewable Energy Technology, Ministry of Education

(Northeast Electric Power University), Jilin 132012, Jilin Province, China)

ABSTRACT: Both the traditional time-of-use tariff (TOUT) and the real-time price (RTP) demand response mechanism will generate new load peaks during the low load period. To solve this problem, considering the demand for peak load regulating on the grid side and the different needs and willingness of different users for charging capacity and charging costs, a dynamic optimization method for TOUT was proposed. The proposed method dynamically updateed the peak-to-valley price of each electric vehicle (EV) based on the load information when the EV was connected to the grid, which made up for the shortcomings of the TOUT and RTP charging methods. Based on the proposed dynamic optimization method of TOUT, by establishing a multi-objective function with the most charging capacity and the least charging cost, the particle swarm optimization (PSO) was used to optimize the charging (discharging) behavior of each EV in two stages. And by introducing a virtual state of charge (SOC) to modify the optimized charging (discharging) behavior, each user autonomously responded to realize the coordinated charging (discharging) of the EV. To verify the effectiveness of the proposed method, based on the results of the 2017 National Household Vehicle Survey (NHTS2017), the Monte Carlo (MC) method was used to simulate the charging demand of 1,000 EVs in a residential area. And the charging demand under different charging strategies, different optimization weights, different participation levels and different V2G (vehicle to grid) responsiveness was simulated and analyzed. The results show that compared with other charging strategies, the

基金项目: 吉林省科技厅国际科技合作项目(20210402080GH)。
International Scientific and Technological Cooperation Project of Jilin
Provincial Department of Science and Technology (20210402080GH).

proposed optimization strategy can significantly reduce the user's charging cost and the peak-to-valley difference of the load curve.

KEY WORDS: electric vehicle; coordinated charging and discharging; optimization strategy; PSO algorithm

摘要: 传统分时电价(time-of-use tariff, TOUT)和实时电价 (real-time price, RTP)需求响应机制均会在负荷低谷时段产 生新的负荷高峰,针对这一问题,考虑电网侧的调峰需求以 及不同用户对充电电量、充电成本的不同需求和参与意愿, 提出一种分时电价动态优化方法。所提方法根据每辆电动汽 车(electric vehicle, EV)接入电网时的负荷信息动态更新该 EV 的峰谷电价, 弥补了 TOUT 和 RTP 充电方式的缺点。基 于所提分时电价动态优化方法,通过建立充电电量最多和充 电成本最小多目标函数,采用粒子群算法对每辆 EV 的充 (放)电行为进行两阶段优化,并通过引入虚拟荷电状态对优 化后的充(放)电行为进行修正,由每位用户自主响应实现 EV 的有序充(放)电。为验证所提方法的有效性,基于 2017 年全美家用车辆调查结果(NHTS2017),采用蒙特卡洛法模 拟某居民区 1000 辆 EV 的充电需求,并对不同充电策略、 不同优化权重、不同参与度和不同 V2G(vehicle to grid)响应 度下的充电需求进行了仿真分析,结果表明,相较于其他充 电策略,所提优化策略可以明显降低用户的充电成本和负荷 曲线的峰谷差。

关键词: 电动汽车; 有序充放电; 优化策略; 粒子群算法

0 引言

近年来,电动汽车(electric vehicle, EV)产业迅猛发展,然而,由于 EV 用户的充电行为具有很大的随机性和不确定性 $^{[1-2]}$,大规模 EV 接入电网后将会增加对电网的控制难度 $^{[3-4]}$,如增大网络损耗 $^{[5-6]}$ 、

影响电压质量^[7-8]、降低电力系统的可靠性^[9-10]等。此外,研究表明,用户给 EV 充电的时间与其生活用电时间大致吻合^[11],这意味着规模化的 EV 无序充电时,充电负荷将与基础负荷叠加,进一步增大负荷曲线的峰谷差。因此,制定有效的有序充电优化策略,对 EV 进行合理的充电安排是降低上述不利影响、推动 EV 产业长久发展的有效途径^[12-13]。

传统分时电价(time-of-use tariff, TOUT)需求响 应[14-16]是传统的需求侧管理方式之一。文献[17]根 据用户对电价的响应特性引导 EV 的充电行为,以 运营商购电成本和各时段引导后的充电负荷与目 标充电负荷方差最小为目标,分别用线性规划和粒 子群(particle swarm optimization, PSO)算法进行优 化,降低了充电成本和负荷曲线的峰谷差率。文 献[18]用 MC 法模拟用户的充电需求,以用户充电 成本最低和起始充电时间最早为目标进行多目标 优化求解, 实现了削峰填谷和降低充电成本双重目 标。文献[19]提出两阶段多目标有序充电控制策略, 第1阶段由MC法模拟EV集群充电行为,将高峰 时段的充电负荷转移至平时段和低谷时段;第2阶 段根据预测误差大小进一步优化高峰时段的充电 负荷实现多方面效益。文献[20]利用 TOUT 对冷/ 热/电综合能源系统在大时间尺度和小时间尺度的 协调运行和不确定性变化进行了优化调度,在一定 程度上发挥了多种设备互补运行的优越性。上述文 献均是在 TOUT 需求响应的基础上开展的 EV 有序 充电策略研究, 然而当大规模电动汽车接入电网 后,TOUT 需求响应引导下的有序充电容易在电价 低谷时段产生新的负荷高峰[21-23]。因此,规模化的 EV 接入电网后, TOUT 需求侧响应机制将无法适 应电网的调峰需求。

相比于 TOUT,实时电价(real-time price, RTP) 需求响应机制在引导用户的充电行为、平抑负荷曲线方面有了少许优势。文献[24]提出一种基于价格信号的充电引导方法,将日前电价与 RTP 相结合,有效地兼顾了电网侧和用户的利益。文献[25]利用 RTP 机制通过更新补贴费用来引导用户对充电桩的选择与匹配,达到车—桩平衡的目的。然而 RTP 的本质同 TOUT 一样,即每隔一段时间对电价进行更新,其引导用户参与电网调峰的效果取决于 RTP 对电价实时更新的时间间隔,当更新时间间隔较长时,在电动汽车数量较多、充电功率较大的情况下,PTP 充电策略也会导致低电价时段产生新的负荷尖

峰^[26]或难以有效改善负荷峰均比^[27],而无限制地减小更新时间间隔又会使用户不能及时响应电价的变化速度。

综上所述, TOUT 和 RTP 需求响应机制均会在 负荷低谷时段出现新的负荷高峰, 在未来电动汽车 大规模接入电网的背景下, TOUT 和 RTP 充电策略 将不再适用。为此,文献[28]提出基于虚拟电价理 论的 EV 充放电优化调度方法, 使得 EV 集群规模 较大时仍可平滑负荷曲线,避免了峰谷奇异现象, 但文献所提虚拟电价仅作为制定车辆充放电计划 的依据指标,并不用于计算实际成本,这为用户充 电成本的可视化带来了不便。文献[29]提出一种基 于双重电价的 EV 充放电优化策略,第1阶段利用 分时电价实现了停泊时间较长的 EV 充电优化调 度,第2阶段利用动态实时电价实现了停泊时间较 短的 EV 充电优化调度,但文献所提方法没有考虑 不同用户对充电电量和充电成本的不同需求,且上 述研究均未充分考虑 EV 参与电网调峰需求时每位 用户是否选择参与 V2G 的意愿。

基于上述研究,本文在 TOUT 和 RTP 的基础 上综合考虑了电网侧的调峰需求和不同用户对充 电电量、充电成本的需求以及对是否参与 V2G 的 意愿,提出一种分时电价动态优化方法,即根据每 辆 EV 接入电网后的负荷信息对电价进行动态更 新,继而采用 PSO 算法根据动态的电价信息分两阶 段对每辆 EV 的充放电行为进行优化,并由用户自 主响应。所提方法中,第1阶段为谷时段优化,首 先为接入电网的 EV 划分峰平谷时段,并更新该辆 EV 并网时的峰谷电价,通过引入充(放)电控制系数 对 EV 在谷时段的充电行为进行优化; 第 2 阶段建 立充电电量最多和充电成本最小多目标函数,考虑 约束条件采用 PSO 优化算法对峰、平时段 EV 的充 放电控制系数进行优化, 并通过引入虚拟荷电状态 (state of charge, SOC)对优化后的充放电控制系数 进行修正, 最终实现 EV 的有序充(放)电以及充电 成本、充电电量的提前计算,便于用户根据自身需 求对充(放)电行为做出决策。为验证所提方法的有 效性,基于 NHTS2017 数据库采用 MC 法模拟用户 的出行行为,对不同充电方式、不同优化权重、不 同参与度和不同 V2G 响应度下的充电需求进行 了仿真实验、验证了所提优化策略的有效性和合 理性。

1 电动汽车充电负荷建模

为方便计算,将一天离散化为 96 个时间段,每个时间段时长为 15min,本文所提到的时间均为离散化后的时段,所提到的时长均为以 15min 为间隔的时间段数量。EV 充电负荷建模过程如下:

1.1 接入/离开电网时间

研究表明,大多数(70%)的用户习惯每天只给 EV 充一次电,且在最后一次出行返程回家后开始 为 EV 充电,充电时间集中在晚上^[12]。因此在对居 民区 EV 充电负荷进行建模时,认为用户回到家时 即将 EV 接入电网,下一次出行时 EV 即离开电网。

NHTS2017 是 2016 年 4 月至 2017 年 4 月在美国开展的全美家用车辆的调查结果的最新版本,该数据库有 129696 户家庭中 264234 个个体和 256115 辆私家车的详细记录,包括每段行程的起始时间、结束时间、行驶距离、出发地和目的地等信息。因此本文根据 NHTS2017 出行数据对工作日以"家(home, H)"为起点、以"工作区(work, W)"为终点的出行规律(H-W)和以"工作区"为起点、以"家"为终点的出行规律(W-H)进行拟合,得到居民区 EV接入/离开电网时间的概率密度函数(probability density function, PDF),再利用 MC 模拟法即可得到该分布规律下每辆 EV 接入/离开电网的时间。

高斯拟合在拟合数据时具有简单快捷的特点,本文采用高斯分布对数据进行拟合,高斯拟合推导过程见附录 1。为观测拟合结果得到的高斯曲线特征,对高斯概率密度函数进行简化,如式(1)所示。

$$y = \sum_{k=1}^{M} a_k \exp[-(\frac{x - b_k}{c_k})^2]$$
 (1)

式中 a、b、c 分别为高斯曲线的峰值、峰值位置和半宽度信息。工作日 H-W 的出行时间、工作日 W-H 到达时间的拟合结果分别如图 1、2 所示,分布参数拟合结果如附表 A1 所示。

为检验拟合效果,常常采用拟合优度来定量分

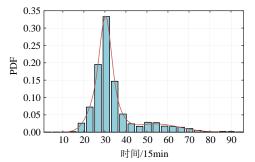


图 1 工作日 H-W 出行时间拟合结果

Fig. 1 Fitting results of H-W travel time on weekdays

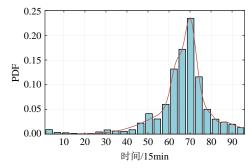


图 2 工作日 W-H 到达时间拟合结果

Fig. 2 Fitting results of W-H arrival time on weekdays 析拟合结果与实际样本之间的误差。高斯拟合中评价拟合优度的指标有拟合误差(sum of squares due to error, SSE)、均方根误差(root mean squared error, RMSE)和确定系数(coefficient of determination, R-square)等,其中常用的指标是确定系数,其值在0~1 之间,确定系数越接近 1,表明方程的变量对拟合结果的解释能力越强,即拟合优度越高,本文以R-square=0.99为指标判断拟合优度。工作日 H-W出行时间和 W-H 到达时间的拟合优度如表 1 所示,可以看出,H-W出行时间和 W-H 到达时间的拟合优度均大于 0.99,表明拟合优度符合本文的检验标准。

表 1 拟合优度 Table 1 Goodness of fit

模式	H-W	W-H
R-square	0.9991	0.9912

1.2 停车时长

EV 接入电网时间与离开电网时间的关系有两种情况(如图 3 所示),即接入电网时间和离开电网时间都在 1 日内完成,或接入电网时间在前 1 天,离开电网时间在第 2 天,则车辆的停车时长可表示为

$$t_{\text{park},k} = \begin{cases} t_{\text{out},k} - t_{\text{in},k}, & 1 \le t_{\text{in},k} < t_{\text{out},k} \le 96 \\ 96 - t_{\text{in},k} + t_{\text{out},k}, & 1 \le t_{\text{out},k} < t_{\text{in},k} \le 96 \end{cases}$$
(2)

式中: $t_{\text{park},k}$ 为车辆 EV_k 的停车时长; $t_{\text{in},k}$ 、 $t_{\text{out},k}$ 分别 为 EV_k 的接入电网时间和离开电网时间。

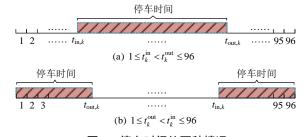


图 3 停车时间的两种情况

Fig. 3 Two situations of parking time

1.3 充放电控制系数

EV 在接入电网后会有 3 种状态: 充电、放电和静默(既不充电也不放电)。为了方便控制每辆 EV的充放电行为,引入充放电控制系数:

$$X_k = zeros[x_{k,1}, x_{k,2}, \dots, x_{k,96}]$$
 (3)

式中: X_k 为车辆 EV_k 充放电控制系数的集合; zeros 表示 X_k 初始化为零向量;元素 $x_{k,1}$ ~ $x_{k,96}$ 为该 EV 每个时段的充放电控制系数,用来控制车辆 EV_k 每个时段的充放电行为及充放电功率的大小,控制规则为如式(4)所示:

$$\begin{cases} 0 < x_{k,t} \le 1, & \text{充电} \\ x_{k,t} = 0, & \text{静默} \\ -1 \le x_{k,t} < 0, & \text{放电} \end{cases}$$
 (4)

1.4 实际所需充电时长

EV的实际所需充电时长为

$$t_{c,k} = \frac{(S_{e,k} - S_{0,k})C_k}{\eta_c P_k} \times 4 \tag{5}$$

式中: $t_{c,k}$ 为车辆 EV_k 的实际所需充电时长; $S_{e,k}$ 为 该 EV 用户的 SOC 期望值; $S_{0,k}$ 为车辆 EV_k 的初始 SOC; C_k 为车辆 EV_k 的电池容量,kW h; η_c 为充电效率; P_k 为车辆 EV_k 的充放电功率,kW; 乘数 4 代表将 $t_{c,k}$ 换算成间隔为 15min 的时间段。

2 电动汽车充放电优化策略模型

2.1 目标函数

EV 循环充放电会带来电池退化问题^[30-31],因此,电池退化带来的充放电费用应当考虑在内。文献[32]给出的电池循环次数与寿命的关系曲线如图 4 所示(数值由电池制造商给出),电池退化成本如式(6)所示。

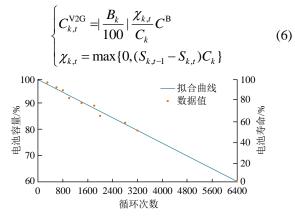


图 4 纳米磷酸铁锂电池循环次数-寿命曲线关系

Fig. 4 Cycle times-life curve relationship of nanometer lithium iron phosphate battery

式中: $C_{k,t}^{V2G}$ 为车辆 EV_k 在 t 时段的电池退化成本,元; B_k 为电池寿命与循环次数之间的线性关系系数,即图 4 的拟合曲线斜率; $\chi_{k,t}$ 为车辆 EV_k 在 t 时段的循环充放电电量,kW h; C^B 为电池更换成本,元; $S_{k,t}$ 、 $S_{k,t-1}$ 分别为车辆 EV_k 在 t 时段的 SOC。

式(6)表明,当车辆 EV_k 在 t 时段参与 V2G 放电时,有 $S_{k,t-1} > S_{k,t}$,即($S_{k,t-1} - S_{k,t}$) $C_k > 0$,此时 $\chi_{k,t}$ 取值为正,因此 $C_{k,t}^{V2G} > 0$, EV_k 有电池损耗成本;而当车辆 EV_k 在 t 时段进行充电时,有 $S_{k,t-1} < S_{k,t}$,即 ($S_{k,t-1} - S_{k,t}$) $C_k < 0$,此时 $\chi_{k,t}$ 取值为 0,因此 $C_{k,t}^{V2G} = 0$, EV_k 没有电池损耗成本。综上所述,当车辆 EV_k 在 t 时段进行 V2G 放电时,将会增加额外的电池循环充放电成本,而进行充电时则不会增加电池损耗成本。

考虑用户参与有序充放电的经济性,同时尽可能让响应 V2G 的用户在谷时段充电、在峰时段放电,达到"削峰填谷"的目的,以满足电网侧的调峰需求。考虑电池循环充放电成本后,以车辆 EV_k 的充放电成本最低为目标函数:

$$\begin{cases}
\min f_{k,1} = \sum_{t=1}^{96} \left(\frac{x_{k,t} w_t P_k}{4} + C_{k,t}^{V2G} \right) \\
w_t \in \{w_{cp}, w_{cf}, w_{cv}, w_{dp}, w_{df}, w_{dv} \}
\end{cases}$$
(7)

式中: $f_{k,1}$ 为考虑电池损耗后车辆 EV_k 的充放电成本,元; S_t 为 t 时段的充放电电价,元/(kW h); w_{cp} 、 w_{cf} 、 w_{cv} 分别为峰时段、平时段、谷时段的充电电价,元/(kW h); w_{dp} 、 w_{df} 、 w_{dv} 分别为峰时段、平时段、谷时段的放电电价,元/(kW h)。

为满足用户的出行需求,以 EV 所充的电量最 多为目标函数:

$$\min f_{k,2} = -\left[S_{0,k} + \frac{1}{4} \sum_{t=1}^{96} x_{k,t} \frac{P_k}{C_k}\right]$$
 (8)

式中 $f_{k,2}$ 为车辆 EV_k 充放电完成后的 SOC。

基于线性加权和法,将目标函数 $f_{k,1}$ 、 $f_{k,2}$ 进行规范化处理,如式(9)所示。

$$\begin{cases}
\min f_{k} = \lambda_{k,1} \left(\frac{f_{k,1}}{f_{k,1}^{\max}} \right) + \lambda_{k,2} \left(\frac{f_{k,2}}{f_{k,2}^{\max}} \right) \\
\lambda_{k,1} + \lambda_{k,2} = 1
\end{cases} \tag{9}$$

式中: f_k 为车辆 EV_k 的多目标优化函数; $f_{k,1}^{\max}$ 、 $f_{k,2}^{\max}$ 分别为单目标函数 $f_{k,1}$ 、 $f_{k,2}$ 的最大值; $\lambda_{k,1}$ 、 $\lambda_{k,2}$ 分别为单目标函数 $f_{k,1}$ 、 $f_{k,2}$ 的优化权重。

2.2 约束条件

1) 充放电功率约束:

$$\begin{cases}
0 \le P_{C,k,t} \le P_{C\max,t} \\
0 \le P_{DC,k,t} \le P_{DC\max,t}
\end{cases}$$
(10)

式中: $P_{C,k,t}$ 、 $P_{DC,k,t}$ 分别为车辆 EV_k 在 t 时段的充电功率和放电功率; $P_{Cmax,t}$ 、 $P_{DCmax,t}$ 分别为 EV 充功率和放电功率允许的最大值。

2) 电池可用容量约束。

EV 蓄电池的寿命除了与循环放电次数有关, 还与放电深度有关,为避免电池过度充放电,对电 池的可用容量进行约束:

$$\begin{cases} S_{\min} \leq S_{k,t} \leq S_{\max} \\ S_{k,t} = S_{k,t-1} + \frac{P_k}{C_k} \times \frac{1}{4} \end{cases}$$
 (11)

为保证电池的使用寿命,电池 SOC 可用容量的上下限 S_{max} 、 S_{min} 一般分别取 1 和 0.3。

3)变压器容量约束。

任意时段内,基础负荷与该时段内接入电网的所有 EV 充电负荷之和不得超过变压器的最大限值:

$$\sum_{k=1}^{N} (P_{C,k,t} - P_{DC,k,t}) + P_{load,t} \le S_{T}$$
 (12)

式中: N 为接入电网中的 EV 数量; $P_{load,r}$ 为时段 t 内电网中的基础负荷, kW; S_T 为变压器容量限值。

4) 用户出行需求约束。

为保证用户的出行需求,用户离开时的 S_{fk} 应不低于用户设置的期望值 $S_{e,k}$,且电量不超过电池容量:

$$S_{e,k} \le S_{f,k} \le 1 \tag{13}$$

5) 可调度时间约束。

由于 EV 的充放电行为只在其接入电网时间内进行,因此 EV 接入电网前和退出电网后的充放电控制系数均为 0,在并网时间内 EV 方可接受调度:

$$t_{\text{in }k} \le t_{\text{V2G},k} \le t_{\text{out }k} \tag{14}$$

$$\begin{cases}
C_{X_k} A_k = 0 \\
A_k = \{x_{k,t_{in,k}}, x_{k,t_{in,k}+1}, \dots, x_{k,t_{out,k}-1}\}
\end{cases}$$
(15)

式中: t_{V2Gk} 为车辆 EV_k 参与有序充放电的可调度时间;集合 A_k 中的元素为车辆 EV_k 并网时间对应的充放电控制系数。

式(15)表明 EV 接入电网前和退出电网后的充

放电控制系数均为 $0,A_k$ 在 X_k 中的补集元素均为0。

3 有序充放电两阶段充电优化策略

3.1 第 1 阶段充电优化

当第 k 辆电动汽车 EV_k 接入电网时,系统通过 EV 的电池管理系统获取该车辆的电池容量 C_k 以及 车辆当前的 SOC,并记录该车辆的接入电网时间 $t_{in,k}$ 。为合理安排充放电计划,用户需输入车辆退出 电网的时间 $t_{out,k}$ 、用户离开时的 SOC 期望值 $S_{e,k}$ 、优化权重 $\lambda_{k,1}$ 、 $\lambda_{k,2}$ 以及是否响应 V2G 放电。

EV 的停车时长与实际所需充电时长的关系有两种情况,如图 5 所示。当满足图 5(a)所示情况,即 EV 的实际所需充电时长不小于停车时长时,该车辆不满足有序充放电条件,该车辆将进行无序充电;当满足图 5(b)所示情况,即 EV 的实际所需充电时长小于停车时长时,该 EV 满足有序充放电条件,系统将安排该 EV 进行有序充放电。

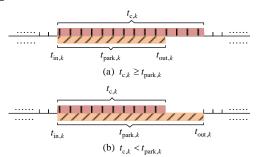


图 5 有序充放电条件判断示意图

Fig. 5 Schematic diagram of coordinated charging and discharging conditions judgment

当车辆 EV_k 满足有序充放电条件时,系统首先 安排该 EV 进行第 1 阶段有序充电,具体流程如下:

1) 将车辆 EV_k 接入时电网中的每个时段的负荷按大小进行升序排序:

$$T_k = sort_{Load}\{t_1, t_2, \dots, t_{96}\}$$
 (16)

式中: T_k 为车辆 EV_k 接入时电网中 96 个时段升序排列后的集合; $t_1 \sim t_{96}$ 为 1 天内离散化后的时间段; $sort_{Load}$ 表示每个时段按负荷大小升序排列。

2)为车辆 EV_k 划分峰谷时段: 考虑峰谷电价对每位车主的公平性, 每辆 EV 在 1 天内的峰、平、谷时段的比例相同, 本文将 T_k 按 1:1:1 的比例划分峰、平、谷时段:

$$\begin{cases}
T_{p}^{k} = \{T_{1}, T_{2}, \dots, T_{32}\} \\
T_{f}^{k} = \{T_{33}, T_{34}, \dots, T_{64}\} \\
T_{v}^{k} = \{T_{65}, T_{66}, \dots, T_{96}\}
\end{cases}$$
(17)

式中 T_p^k 、 T_f^k 、 T_v^k 分别为车辆 EV_k 接入电网时段内峰、平、谷时段的集合。

3) 将车辆 EV_k 接入电网时段内所有的谷时段设置为以额定功率进行充电:

$$\begin{cases} \{x_{k,t}\} = 1 \\ x_{k,t} \in A_k \\ t \in T_v^k \end{cases}$$
 (18)

式中集合 $\{x_{k,t}\}$ 中的元素为车辆 EV_k 并网时间内谷时段对应的充放电控制系数。

至此,车辆 EV_k 的谷时段优化控制系数已经设置完毕,值得注意的是,并不是所有的车辆在其停车时间内都有谷时段存在,因此第 1 阶段对谷时段控制量的优化并不是每辆 EV 都能参与。此时车辆 EV_k 并未开始充电,还需经过第 2 阶段的优化控制。

3.2 第2阶段充放电优化

令车辆 EV_k 停车时间内的峰时段和平时段的数量为 N_k ,假设某辆电动汽车 EV_k 经第 1 阶段充电优化后,第 2 阶段充放电优化时段分布如图 6 所示。

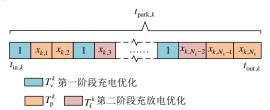


图 6 车辆 EV_k 第 2 阶段充放电优化时段分布

Fig. 6 Charge and discharge optimized period distribution for the second stage of \mathbf{EV}_k

利用 PSO 对车辆 EV_k 的峰时段和平时段的充放电控制系数进行优化时,PSO 通过初始化为一群随机粒子(随机解),然后通过迭代找到最优解。假设每个种群由 M 个粒子组成,则第 i 个粒子的初始位置和速度均为维数为 N_k 的向量:

$$\begin{cases} x_i^k = [x_{i,1}^k, x_{i,2}^k, \dots, x_{i,N_k}^k], & i = 1, 2, \dots, M \\ v_i^k = [v_{i,1}^k, v_{i,2}^k, \dots, v_{i,N_k}^k], & i = 1, 2, \dots, M \end{cases}$$
(19)

式中 x_i^k 、 v_i^k 分别为车辆 EV_k 在寻优过程中第i个粒子的位置和速度。

充放电控制系数的粒子经过随机初始化后,车辆 EV_k 接入电网时间内每个时段的充放电控制系数已经预设完成,但考虑电池容量的约束,需对初始化的充放电控制系数进行修正。引入虚拟 SOC 变量,按照车辆 EV_k 初始化的充放电控制系数 $x_{k,t}$ 依

次计算每个时段充放电行为完成后的虚拟 SOC:

$$S_{k,t}^{v} = S_{k,t-1} + x_{k,t} \frac{P_k}{C_k} \times \frac{1}{4}$$
 (20)

式中 $S_{k,t}^{v}$ 、 $S_{k,t-1}$ 分别为车辆 EV_k 本时段的虚拟 SOC 和上一时段的实际 SOC; $x_{k,t}$ 为车辆 EV_k 本时段初始化的充放电控制系数。充放电控制系数的修正流程如下:

1)当某时段虚拟 SOC 大于上限 S_{max} 时,系统 对该时段的充放电控制系数进行如下修正:

$$x_{k,t} = \begin{cases} -1, & t \in \{T_p^k, T_f^k\} \\ 0, & t \in \{T_v^k\} \end{cases}$$
 (21)

式(21)表明当某时段的虚拟 SOC 大于上限 S_{max} 且该时段为峰时段或平时段时,该时段将修正为以额定功率放电;当该时段为谷时段时,该时段将修正为静默。

2)当某时段虚拟 SOC 小于下限 S_{min} 时,系统 对该时段的充放电控制系数进行如下修正:

$$x_{k,t} = 1, \quad t \in \{T_{p}^{k}, T_{f}^{k}, T_{y}^{k}\}$$
 (22)

式(22)表明当某时段的虚拟 SOC 小于下限 S_{min} 时,无论该时段是峰时段、平时段还是谷时段,该时段都将修正为以额定功率充电。

充放电控制系数修正完成之后, 粒子群进行迭 代寻优, 第 *i* 个粒子搜寻到的最优位置称为个体极 值, 记为

$$p_{\text{best}}^{k} = [p_{i,1}^{k}, p_{i,2}^{k}, \dots, p_{i,N_{k}}^{k}]$$
 (23)

整个种群在该次迭代过程中迄今为止搜寻到 的最优解称为全局极值,记为

$$g_{\text{best}}^{k} = [p_{g1}^{k}, p_{g2}^{k}, \dots, p_{gN_{c}}^{k}]$$
 (24)

当整个粒子种群找到个体极值 p_{best}^k 和全局极值 p_{best}^k 后,该次迭代完成,每个粒子将通过如下公式更新自己的位置和速度:

$$\begin{cases} v_{i,t}^{k} = \omega v_{i,t}^{k} + c_{1} r_{1} (p_{i,t}^{k} - x_{i,t}^{k}) + c_{2} r_{2} (p_{gt}^{k} - x_{i,t}^{k}) \\ x_{i,t}^{k} = x_{i,t}^{k} + v_{i,t}^{k} \\ t = 1, 2, \dots, N_{k} \end{cases}$$
(25)

式中: $v_{i,t}^k$ 、 $x_{i,t}^k$ 分别为车辆 EV_k 充放电寻优过程中第i个粒子在第t时段的速度和位置; ω 为惯性权重; c_1 、 c_2 为学习因子,也称加速常数; r_1 、 r_2 为2个在[0,1]之间变化的加速度权重系数。粒子的位置和速度完成更新后将进行下一次迭代,直到完成所有的迭代过程,最终得到的最佳适应度值即为粒子群

的最优值。

至此车辆 EV_k 的两阶段充放电优化完成,该辆

EV 开始执行充放电,两阶段充放电优化流程图如图 7 所示。

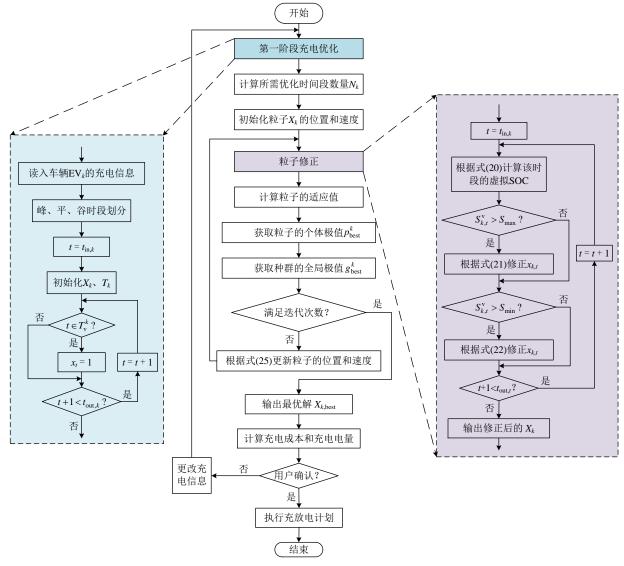


图 7 两阶段充放电优化流程

Fig. 7 Two-stage optimization process of charging and discharging

4 算例分析

4.1 参数设置

以某居民区为例,其基础负荷参照文献[21]中 IEEE33 节点配电系统的基础负荷分布,如表 2 所

表 2 IEEE33 节点基础负荷分布

Table 2 Basic load distribution of IEEE33 nodes

时刻	负荷/kW	时刻	负荷/kW	时刻	负荷/kW
01:00	1625.3	09:00	3018.4	17:00	2321.9
02:00	1741.4	10:00	3250.6	18:00	3018.4
03:00	1973.6	11:00	3482.8	19:00	3482.8
04:00	2205.8	12:00	3250.6	20:00	3715.0
05:00	2321.9	13:00	3018.4	21:00	3018.4
06:00	2554.1	14:00	2879.1	22:00	2554.1
07:00	2670.2	15:00	2786.3	23:00	2089.7
08:00	2786.3	16:00	2438.0	24:00	1857.5

示,经拟合后得到本文96个时段的基础负荷。

假设该区域有 1000 辆电动汽车,电池容量为 35kW h。 我国明确提出在 2020 年需要将电池生产价格降低到 $1 \, \pi/(W \, h)$,由此设置电池更换成本 $C^B=35\,000\,\pi$ 。设置最大充放电功率均为 3.3kW,充电效率为 0.9,假设居民区有 4 台容量均为 1600kVA 的变压器,EV 起始 SOC 满足正态分布 $N_{Ts}(50,10^2)$ 。设置 PSO 进化次数为 1000,种群规模为 1000,学习因子 $c_1=c_2=1.5$ 。分时电价的峰、平、谷电价以北京市一般工业的峰谷电价为标准,如表 3 所示。

基于上述理论和数据,采用 MC 法对该区域 1 天内 1000 辆 EV 不同场景下的充放电行为进行模拟,即可得到不同场景下充电需求的预测结果,仿真流程如图 8 所示。

表 3 北京市一般工业分时电价

Table 3 Time-of-use tariff of general industrial in Beijing

时段类型	时段划分	电价(元/(kW h))
峰时段	10:00—15:00 18:00—21:00	1.322
平时段	7:00—10:00 15:00—18:00	0.832
干时权	21:00—23:00	0.832
谷时段	23:00—7:00	0.369
	开始	

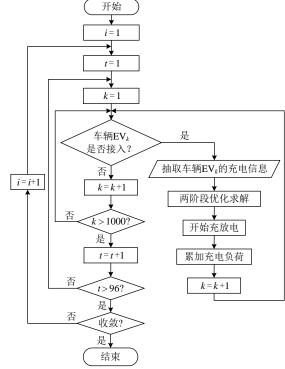


图 8 基于 MC 法的有序充放电流程

Fig. 8 Coordinated charging and discharging process based on MC method

4.2 仿真结果

1) 不同充电策略下的充电需求。

为验证本文所提有序充(放)电优化策略的有效性,模拟该居民区分别在本文所提优化策略(仅充电和充放电)、TOUT、RTP和无序充电这五种充电方式下的充电需求,其中用户在本文所提优化策略下进行有序充放电时,优化权重由每位用户根据式(26)自主随机选择。值得一提的是,为控制单一变量,需要保证每种充电方式下EV所充的总电量一致。

$$\begin{cases} \lambda_1 = \text{rand}\{0, 0.1, 0.2, 0.3, 0.4, 0.5\} \\ \lambda_2 = 1 - \lambda_1 \end{cases}$$
 (26)

式中 rand 表示用户对优化权重进行选择,且满足随机分布。

设置本文方法、TOUT 和 RTP 的峰、平、谷电价为表 3 中的电价,且 RTP 充电方式下设置为每隔 30min 更新峰谷电价,无序充电(固定电价)的电价

为上述峰平谷电价的平均值 0.841 元/(kW h)。在其他仿真参数一致的前提下,对该居民区 1000 辆 EV 不同充电策略下的充电需求进行预测,本文所提优化策略下仅充电优化与其他充电方式下的充电需求预测结果如图 9 所示;本文所提优化策略下充放电优化与其他充电方式下的充电需求预测结果如图 10 所示。

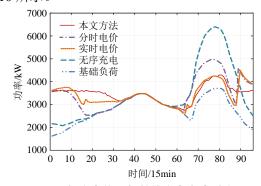


图 9 仅充电优化与其他充电方式对比

Fig. 9 Comparison of charging only optimization and other charging methods

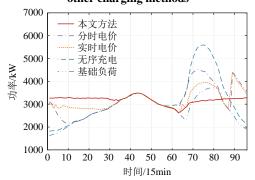


图 10 充放电优化与其他充电方式对比

Fig. 10 Comparison of charging and discharging optimization with other charging methods

由图 9、10 可以看出,受人们生活习惯和用电方式的影响,用户的充电行为集中在下午和夜间,基础负荷在中午和晚上各有一个负荷高峰。无序充电时,由于用户习惯在晚上给 EV 充电,这种充电习惯与人们的生活用电习惯相一致,导致夜间的基础负荷与无序充电负荷相叠加,出现了"峰峰叠加"的现象(如第 70—80 时段)。在 TOUT需求响应机制下,由于用户追求充电成本的经济性,大多数用户会选择在固定的谷时段将 EV 接入电网,导致在基础负荷低谷时段出现了新的高峰(如第 88—96 时段)。由 TOUT 与 RTP 下电动汽车充电需求仿真曲线的对比可以看出,相比于TOUT,RTP需求响应机制能更好地引导用户的充电行为,平抑负荷曲线,但由于 RTP 的本质同TOUT 一样,只是每隔一段时间对峰谷电价进行更

新,因此在电动汽车并网数量较集中的时间段, 会有大量的用户选择在实时电价低谷时段将电 动汽车接入电网(如图中的第88—90时间段),这 依然会使负荷曲线在负荷低谷时段出现新的负 荷高峰。

而在本文所提充放电优化策略下,无论是仅充电优化还是充放电优化,负荷曲线的波动均有明显的改善,通过对比图 9、10 中本文方法下的负荷曲线,可以看出本文优化策略下对充放电优化的削峰(第 70—84 时段)、填谷(第 85—96 时段、第 1—34 时段)效益更加显著。

为定量分析该优化策略在仅充电优化和充放 电优化时的有效性,在保证充电总电量和其他仿真 参数一致的前提下,分别计算各种充电方式下 EV 的起始 SOC 平均值、离网 SOC 平均值、充电成本 以及负荷曲线的峰谷差和方差,计算结果如表 4、5 所示。

表 4 仅充电优化与其他充电方式定量对比
Table 4 Quantitative comparison between charging only optimization and other charging methods

	•		0	8	
充电策略	起始 SOC	离网 SOC	总充电	峰谷差/	负荷方差/
九 电 東 哈	平均值	平均值	成本/元	kW	kW^2
本文方法			13 175	1.56×10^{3}	1.27×10^7
TOUT	0.5	0.06	10 839	2.44×10^{3}	4.77×10^7
RTP	0.5	0.96	10 421	1.88×10^{3}	1.90×10^7
无序充电			13 695	4.32×10^{3}	1.52×10^{8}
基础负荷	_	_	_	2.08×10^{3}	3.13×10 ⁷

表 5 充放电优化与其他充电方式定量对比

Table 5 Quantitative comparison between charge and discharge optimization and other charging methods

充电策略	起始 SOC 平均值	离网 SOC 平均值	总充电成本/元	循环充放电成本/元	综合充电成本/元	峰谷差/kW	负荷方差/kW ²
本文方法			3333.9	833.4	4167.3	0.85×10^{3}	2.87×10^6
TOUT	0.5	0.77	6003.5	0	6003.5	2.36×10^{3}	4.15×10^7
RTP	0.5	0.77	5701.7	0	5701.7	1.75×10^3	1.73×10 ⁷
无序充电			7954.7	0	7954.7	3.77×10^3	9.59×10^7
基础负荷	_	_	_	_	_	2.08×10^{3}	3.13×10^7

由表 4 可以看出,在充电电量整体水平一致的情况下,相比于其他充电策略,本文所提优化策略在仅充电优化时的负荷峰谷差和负荷曲线方差明显降低,但在充电成本方面,相较于 TOUT 和 RTP 充电策略而言充电成本有所增大,相较于无序充电而言充电成本并没有明显优势。

而由表 5 可以看出,同样在充电电量整体水平一致的情况下,相比于其他充电策略,本文所提优化策略在充放电优化时的综合充电成本、负荷峰谷差和负荷曲线方差均明显降低,其中该 1000 辆 EV在本文所提优化策略进行充放电优化时的综合充电成本(充电成本+循环充放电成本)为 4167.3 元,与RTP 和 TOUT 充电策略相比,综合充电成本分别降低了 30%、25%以上,与无序充电相比降低了近 50%。

2) 同一用户不同权重下的优化结果。

当用户参与本文优化方法时,V2G 放电由用户自主选择是否响应。当用户选择响应 V2G 放电时,考虑到不同用户对充电成本和充电电量的需求不同,每位用户均可自行设置优化权重。以某用户为例,该辆 EV 的充电信息为: $t_{\rm in}$ =65, $t_{\rm out}$ =22, S_0 =0.36,分析该用户不响应 V2G 以及响应 V2G 时选择优化权重分别为 λ_1/λ_2 =0.1/0.9、 λ_1/λ_2 =0.2/0.8、

 $\lambda_1/\lambda_2=0.3/0.7$ 时的充放电优化结果。该辆 EV 接入电网时的电网负荷信息与当前的动态电价信息如图 11 所示,该用户选择不同优化权重时的充放电控制系数及充放电功率分布如图 12 所示(χ_k 为该辆电动汽车的充放电控制系数),优化结果如表 6 所示。

由图 12 和表 6 可以看出,当该用户不响应 V2G 放电时,充放电控制系数均为正值,且充电成本较高,相对于无序充电和 TOUT 充电策略而言并无明显优势。而当用户选择响应 V2G 放电时,充电成本明显降低,且随着充电成本优化权重系数 λ_1 越大时,该用户的综合充电成本越小。当 λ_1 取 0.6 时,用户综合充电成本出现负值,即可以获得充放电收

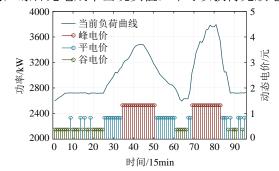


图 11 当前电网负荷与动态电价信息

Fig. 11 The current grid load and dynamic electricity price information

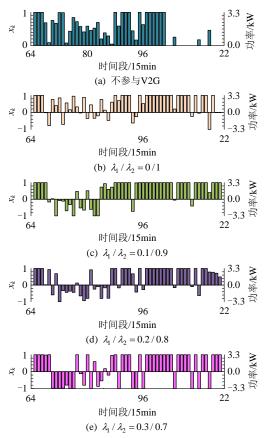


图 12 不同优化权重时的充放电控制系数及 充放电功率分布

Fig. 12 Charge-discharge control coefficient and charge-discharge power distribution with different optimization weights

益。然而随着充电成本优化权重系数 λ_1 越大,充电电量优化权重系数 λ_2 会随之减小,EV 的充电量也会随之降低且循环充放电成本会随之增加,但相较于放电收益而言,所增加的电池损耗成本无太大影响。此外,表 6 显示该用户不响应 V2G 以及响应 V2G 且优化权重选择 λ_1/λ_2 =0/1、 λ_1/λ_2 =0.2/0.8 时,EV 离网时的 SOC 值均为 1。其原因是该 EV 接入电网的时间较长,有足够的可调度时间和优化空间。因此,EV 并网的时间越长,可调度时间越长,优化效果越好。

图 13 展示了该用户在选择不同优化权重进行有序充放电时的 PSO 寻优过程,可以看出不同优化方式均在 500 次迭代以内达到最优,且当用户不参与 V2G 时,收敛速度最快。

3)不同参与度下的优化结果。

为验证参与本文优化策略的用户数量对负荷调峰效益的影响,定义参与度为参与本文优化策略的 EV 数量与需要充电的 EV 总量之比。分析参与度分别为 20%、40%、60%、80%、100%时 EV 充电负荷的削峰填谷效益和峰峰叠加效应,其中不参与本文充放电策略的 EV 假设为无序充电,参与本文充放电优化策略的优化权重同样由用户根据式(26)自主选择。在本文优化策略下仅充电和充放电的削峰填谷效益以及与充电电量相同时的无序

表 6 不同优化权重时的优化结果

Table 6 Optimization results with different optimization weights

		起始	离网	充电	循环充放电	综合充电	充相同电量时的	充相同电量时的
响应情况	λ_1/λ_2	SOC	SOC	成本/元	成本/元	成本/元	无序充电成本/元	TOUT 充电成本/元
不响应 V2G	_		1	16.90	0	16.90		
	0/1		1	11.27	0.26	11.53	22.30	18.73
响应	0.2/0.8	0.36	1	6.51	0.43	6.94		
V2G	0.4/0.6		0.88	1.80	0.58	2.38	20.02	15.26
	0.6/0.4		0.61	-3.34	0.87	-2.50	8.83	7.63

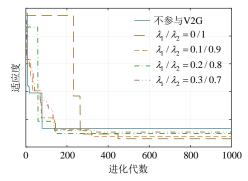


图 13 不同优化权重时的寻优过程

Fig. 13 The optimization process of different optimization weights

充电负荷分别如图 14、15 所示。

为定量分析本文所提充(放)电优化策略不同参与度下 EV 的调峰作用,定义削峰填谷容量和峰峰叠加容量的计算公式为:

$$\begin{cases} C_{\text{pls}} = C_{\text{add},1} + C_{\text{add},2} + C_{\text{cut}} \\ C_{\text{add},1} = \sum_{t_1}^{t_2} L_{\text{DTOUT}} - L_{\text{base}}, \quad L_{\text{DTOUT}} < L_{\text{base}}^{\text{max}} \\ C_{\text{add},2} = \int_{t_3}^{t_4} L_{\text{base}}^{\text{max}} - L_{\text{base}}, \quad L_{\text{DTOUT}} \ge L_{\text{base}}^{\text{max}} \\ C_{\text{cut}} = \int_{t_1}^{t_2} L_{\text{base}} - L_{\text{DTOUT}}, \quad L_{\text{DTOUT}} < L_{\text{base}} \end{cases}$$

$$(27)$$

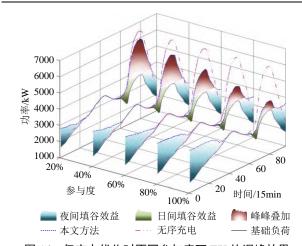


图 14 仅充电优化时不同参与度下 EV 的调峰效果 Fig. 14 The peak load regulating effect for different EV participation levels of only charging optimization

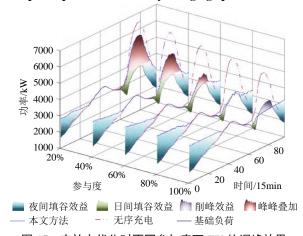


图 15 充放电优化时不同参与度下 EV 的调峰效果
Fig. 15 The peak load regulating effect for different EV participation levels of charging and discharging optimization

$$C_{pip} = \int_{t_1}^{t_2} L_{\text{DTOUT}} - L_{\text{base}}, \quad L_{\text{DTOUT}} > L_{\text{base}}$$
 (28)

式中: C_{pls} 为削峰填谷容量,MW h; L_{DTOUT} 、 L_{base} 分别为本文策略下的负荷曲线和基础负荷曲线; $L_{\text{base}}^{\text{max}}$ 为基础负荷最大值; $C_{\text{add,1}}$ 、 $C_{\text{add,2}}$ 分别为本文充电策略下负荷曲线小于、大于 $L_{\text{base}}^{\text{max}}$ 时的"填谷"容量,MW h; C_{cut} 为"削峰"容量,MW h; C_{ptp} 为"峰峰叠加"容量,MW h。通过式(27)—(28)计算得到不同参与度下 EV 的削峰填谷和峰峰叠加容量如表 7、8 所示。

由图 14、15 可以看出,不论是仅充电还是充放电,相比于无序充电,所提优化策略可以有效地将峰时段的充电负荷转移至谷时段,且随着用户参与度的增大,负荷曲线的峰值随之减小。相比于仅充电而言,相同参与度下充放电能更好地平抑负荷的波动。另外,由于该居民区用户的出行习惯,EV

表 7 仅充电优化时不同参与度下的调峰容量 Table 7 The peak load regulating capacity of only charging optimization for different EV participation

参与度	削峰填谷容量/(MW h)	峰峰叠加容量/(MW h)
20%	8.82	8.39
40%	10.76	6.44
60%	12.37	4.61
80%	14.00	2.71
100%	14.92	1.30

表 8 充放电优化时不同参与度下的调峰容量
Table 8 The peak load regulating capacity of charging and discharging optimization for different EV participation

参与度	削峰填谷容量/(MW h)	峰峰叠加容量/(MW h)
20%	9.80	6.80
40%	11.24	4.20
60%	11.87	1.144
80%	11.18	0.01
100%	9.31	0

在日间的调峰效益并不明显,其原因是白天对 EV 进行充电的用户较少,可调容量较小。

由表 7、8 可知,在本文所提充(放)电优化策略下峰峰叠加效应均随参与度的增大而降低。本文所提优化策略下,仅充电时充电负荷的削峰填谷效益随参与度的增大而增大,但充放电时充电负荷的削峰填谷效益随参与度的增大先增大后减小,其原因是在用户选择的优化权重不变的情况下,通过参与V2G 放电会使充电电量减少,导致填谷效益降低。

4) 不同优化权重和 V2G 响应度下的调峰效果 分析。

定义 V2G 响应度为参 V2G 放电的 EV 数量占 EV 总量的比值,分析不同优化权重下 V2G 响应度分别为 0%、20%、40%、60%、80%、100%时 EV 的调峰作用。固定优化权重下,以充电电量最多单目标优化(λ_1/λ_2 =0/1)时的仿真结果如图 16 所示;多目标优化时优化权重以 λ_1/λ_2 =0.2/0.8 和 λ_1/λ_2 =0.4/0.6 为例,仿真结果分别如图 17、18 所示。用户根据式(26)自主选择优化权重时的仿真结果如图 19 所示。

通过对比图 15—18 可知,不同优化权重与不同 V2G 响应度均会影响 EV 的调峰作用,优化权重相同时,V2G 响应度越高,负荷曲线峰谷差越小,其原因在于当 V2G 响应度较高时,EV 集群的充电负荷转移能力变大,负荷高峰时段更多的充电需求通过优化策略被转移到了负荷谷时段。当 V2G 响

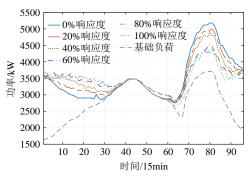


图 16 λ_1/λ_2 =0/1 单目标优化时不同 V2G 响应度下 EV 的调峰效果

Fig. 16 The peak load regulating effect of EVs for different V2G responsivity with $\lambda_1/\lambda_2\!\!=\!\!0/1$

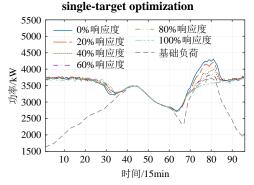


图 17 λ_1/λ_2 =0.2/0.8 多目标优化时不同 V2G 响应度下 EV 的调峰效果

Fig. 17 The peak load regulating effect of EVs for different V2G responsivity with $\lambda_1/\lambda_2 = 0.2/0.8$

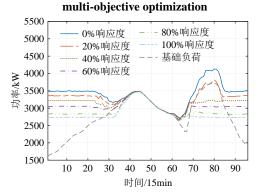


图 18 λ_1/λ_2 =0.4/0.6 多目标优化时不同 V2G 响应度下 EV 的调峰效果

Fig. 18 The peak load regulating effect of EVs for different V2G responsivity with λ_1/λ_2 =0.4/0.6 multi-objective optimization

应度相同时,优化权重 λ_1/λ_2 的值越大,负荷曲线峰谷差越小,其原因在于当集中优化对充电成本目标函数的权值选择越大时,对应充电电量目标函数的权值越小,为追求充电成本的最大化,所提充(放)电策略会尽可能地安排 EV 在平时段和峰时段进行V2G 放电。

另外,用户参与自主优化和固定权值优化时的

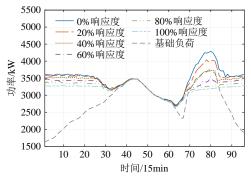


图 19 用户自主优化时不同 V2G 响应度下 EV 的调峰效果

Fig. 19 The peak load regulating effect of EVs for different V2G responsivity with users self-optimize

优化结果也有所差别,固定优化权值时,不同优化权值下的优化结果相差较大,如 λ_1/λ_2 =0/1 时,负荷曲线容易出现负荷峰谷差较大的情况(如图 16); λ_1/λ_2 =0.2/0.8 时,不同 V2G 响应度下的负荷曲线分布较为集中(如图 17);而 λ_1/λ_2 =0.4/0.6 时,不同 V2G 响应度下负荷曲线的分布类似 "平行"状态(如图 18),这是由于所有用户的优化权值相同,系统会按照相同的优化方式对每辆 EV 的充放电行为进行优化,使得每辆 EV 的充放电行为进行优化,使得每辆 EV 的充放电行为有或多或少的共性。而当用户参与自主优化时,由于每位用户的充电需求不同,对优化权值的选择也会有所不同,系统会根据每位用户的需求对每辆 EV 的充放电行为进行优化,不同 V2G 响应度下的负荷曲线分布介于固定优化权值 λ_1/λ_2 =0.2/0.8 和 λ_1/λ_2 =0.4/0.6 之间(如图 19)。

5 结论

针对传统 TOUT 和 RTP 充电策略容易在负荷低谷时段产生新的负荷高峰这一问题,本文考虑电网侧的调峰需求和用户侧的充电需求,提出一种分时电价动态优化方法,通过动态更新每辆 EV 接入电网时的电价信息,基于该优化方法,利用 PSO 算法实现对 EV 的有序充放电优化。基于 NHTS 数据库拟合居民区用户工作日的出行规律,模拟所提优化策略下某居民区 1 天内的充电需求,并通过与其他充电策略的对比以及对优化权重、V2G 响应度的分析验证了本文所提优化策略的可行性和有效性,并得出以下结论:

1)相比于 TOUT、RTP 充电策略和无序充电而言,本文所提 EV 有序充放电提策略能明显降低负荷曲线的峰谷差,且对于响应 V2G 的用户而言可以明显降低用户的充电成本。

- 2)参与 V2G 响应时,会增加电池的循环充放 电成本,且参与循环充放电电量越多,电池损耗成 本越大,但相较于 V2G 放电收益而言,电池损耗 成本可以忽略。
- 3) 在对 EV 的充放电行为进行优化时,不同优化权重 λ_1/λ_2 的取值会影响 EV 充电成本和充电电量,优化权重 λ_1/λ_2 的取值越大,综合充电成本越小,但充电电量也会随之减小。
- 4)不同优化权重和不同 V2G 响应度均能影响 EV 的调峰作用,在 V2G 技术尚未完全普及的背景下,通过控制本文所提有序充放电策略的优化权重来控制 EV 的调峰作用更有实际意义。

本文仅针对电动汽车有序充放电优化策略进 行研究,对激励用户参与有序充放电优化的需求响 应政策仍需进一步研究。

参考文献

- [1] ZHANG Qian, ZHU Yi, WANG Zhong, et al. Reliability assessment of distribution network and electric vehicle considering quasi-dynamic traffic flow and vehicle-to-grid[J]. IEEE Access, 2019, 7:131201-131213.
- [2] JAHANGIR H, GOUGHERI S S, VATANDOUST B, et al. Plug-in electric vehicle behavior modeling in energy market: a novel deep learning-based approach with clustering technique[J]. IEEE Transactions on Smart Grid, 2020, 11(6): 4738-4748.
- [3] 杨健维,杨鹤,张夏霖,等. 基于换电规则优化与车辆—电池组匹配的电动公交车充换电站充电优化策略 [J]. 中国电机工程学报, 2019, 39(8): 2337-2347. YANG Jianwei, YANG He, ZHANG Xialin, et al. A charging optimization strategy on charging and swapping station for electric buses based on optimization of switching rules and matching of buses and batteries[J]. Proceedings of the CSEE, 2019, 39(8): 2337-2347(in Chinese)
- 汽车充放电自动需求响应方法[J]. 中国电机工程学报, 2017, 37(1): 120-129.

 YANG Xiaodong, ZHANG Youbing, ZHAO Bo, et al. Automated demand response method for electric vehicles charging and discharging to achieve supply-demand Coordinated Optimization[J]. Proceedings of the CSEE,

[4] 杨晓东,张有兵,赵波,等.供需两侧协同优化的电动

[5] 侯慧,徐焘,柯贤彬,等. 电动汽车快充对配电网的风险研究[J]. 电力系统保护与控制, 2019, 47(16): 87-93. HOU Hui, XU Tao, KE Xianbin, et al. Research on risks of electric vehicle charging to distribution network[J]. Power System Protection and Control, 2019, 47(16):

2017, 37(1): 120-129(in Chinese).

- 87-93(in Chinese).
- [6] GAN Lei, CHEN Xingying, YU Kun, et al. A probabilistic evaluation method of household EVs dispatching potential considering users' multiple travel needs[J]. IEEE Transactions on Industry Applications, 2020, 56(5): 5858-5867.
- [7] AL-OGAILIAS, JUHANAT, RAHMATNA, et al.
 Review on scheduling, clustering, and forecasting strategies for controlling electric vehicle charging: challenges and recommendations[J]. IEEE Access, 2019, 7(1): 128353-128371.
- [8] SHAFIQ S, IRSHAD U B, AL-MUHAINI M, et al. Reliability evaluation of composite power systems: evaluating the impact of full and plug-in hybrid electric vehicles[J]. IEEE Access, 2020, 8: 114305-114314.
- [9] HABIB S, KHAN M M, ABBAS F, et al. A comprehensive study of implemented international standards, technical challenges, impacts and prospects for electric vehicles[J]. IEEE Access, 2018, 6: 13866-13890.
- [10] KAUR K, KUMAR N, SINGH M. Coordinated power control of electric vehicles for grid frequency support: MILP-based hierarchical control design[J] . IEEE Transactions on Smart Grid, 2019, 10(3): 3364-3373.
- [11] QUIROS-TORTOS J, OCHOA L, BUTLER T. How electric vehicles and the grid work together: lessons learned from one of the largest electric vehicle trials in the world[J]. IEEE Power and Energy Magazine, 2018, 16(6): 64-76.
- [12] 潘振宁, 余涛, 王克英. 考虑多方主体利益的大规模电动汽车分布式实时协同优化[J]. 中国电机工程学报, 2019, 39(12): 3528-3540.

 PAN Zhenning, YU Tao, WANG Keying, et al. Decentralized coordinated dispatch for real-time optimization of massive electric vehicles considering various interests[J]. Proceedings of the CSEE, 2019, 39(12): 3528-3540(in Chinese).
- [13] 黄敏丽,于艾清. 基于改进布谷鸟算法的电动汽车换电站有序充电策略研究[J]. 中国电机工程学报,2018,38(4): 1075-1083.

 HUANG Minli, YU Aiqing. Study on coordinated charging strategy for battery swapping station based on improved cuckoo search algorithm[J]. Proceedings of the CSEE, 2018, 38(4): 1075-1083(in Chinese).
- [14] PRADHAN P, AHMAD I, HABIBI D, et al. Reducing the impacts of electric vehicle charging on power distribution transformers[J]. IEEE Access, 2020, 8: 210183-210193.
- [15] GANGATHARAN S, RENGASAMY M, ELAVARASAN R M, et al. A novel battery supported energy management system for the effective handling of feeble power in hybrid

- microgrid environment[J]. IEEE Access, 2020, 8: 217391-217415.
- [16] 刘敦楠,徐尔丰,刘明光,等.面向分布式电源就地消纳的园区分时电价定价方法[J].电力系统自动化,2020,44(20):19-28.
 - LIU Dunnan, XU Erfeng, LIU Mingguang, et al. TOU pricing method for park considering local consumption of distributed generator[J]. Automation of Electric Power Systems, 2020, 44(20): 19-28(in Chinese).
- [17] 常方字,黄梅,张维戈. 分时充电价格下电动汽车有序 充电引导策略[J]. 电网技术, 2016, 40(9): 2609-2615. CHANG Fangyu, HUANG Mei, ZHANG Weige. Research on coordinated charging of electric vehicles based on TOU charging price[J]. Power System Technology, 2016, 40(9): 2609-2615(in Chinese).
- [18] 孙晓明,王玮,苏粟,等.基于分时电价的电动汽车有序充电控制策略设计[J].电力系统自动化,2013,37(1):191-195.
 - SUN Xiaoming, WANG Wei, SU Su, et al. Coordinated charging strategy for electric vehicles based on time-of-use price[J]. Automation of Electric Power Systems, 2013, 37(1): 191-195(in Chinese).
- [19] 陈奎,马子龙,周思宇,等. 电动汽车两阶段多目标有 序充电策略研究[J]. 电力系统保护与控制,2020,48(1): 65-72.
 - CHEN Kui, MA Zilong, ZHOU Siyu, et al. Charging control strategy for electric vehicles based on two-stage multi-target optimization[J]. Power System Protection and Control, 2020, 48(1): 65-72(in Chinese).
- [20] 王成山,吕超贤,李鹏,等.园区型综合能源系统多时间尺度模型预测优化调度[J].中国电机工程学报,2019,39(23):6791-6803.
 - WANG Chengshan, LÜ Chaoxian, LI Peng, et al. Multiple time-scale optimal scheduling of community integrated energy system based on model predictive control[J]. Proceedings of the CSEE, 2019, 39(23): 6791-6803(in Chinese).
- [21] 张静,汤奕,陈成,等.考虑分时电价和系统峰谷差动态约束的电动汽车有序充电策略[J].电网与清洁能源,2014,30(5):79-84,91.
 - ZHANG Jing, TANG Yi, CHEN Cheng, et al. Coordinated Charging strategy for electric vehicles considering time-of-use price and peak-valley difference dynamic constraints[J]. Power System and Clean Energy, 2014, 30(5): 79-84, 91(in Chinese).
- [22] 程杉,陈梓铭,徐康仪,等. 基于合作博弈与动态分时 电价的电动汽车有序充放电方法[J]. 电力系统保护与控 制,2020,48(21):15-21.
 - CHENG Shan, CHEN Ziming, XU Kangyi, et al. An orderly charging and discharging method for electric

- vehicles based on a cooperative game and dynamic time-of-use price[J]. Power System Protection and Control, 2020, 48(21): 15-21(in Chinese).
- [23] 徐智威,胡泽春,宋永华,等. 基于动态分时电价的电动汽车充电站有序充电策略[J]. 中国电机工程学报, 2014, 34(22): 3638-3646.
 - XU Zhiwei, HU Zechun, SONG Yonghua, et al. Coordinated charging strategy for PEV charging stations based on dynamic time-of-use tariffs[J]. Proceedings of the CSEE, 2014, 34(22): 3638-3646(in Chinese).
- [24] 史一炜,冯冬涵,ZHOUE,等.基于主从博弈的充电服务商充电引导方法及其定价策略[J].电工技术学报,2019,34(S2):742-751.
 - SHI Yiwei, FENG Donghan, ZHOU E, et al. Stackelberg game based on supervised charging method and pricing strategy of charging service providers[J]. Transactions of China Electrotechnical Society, 2019, 34(S2): 742-751(in Chinese).
- [25] 李东东,段维伊,林顺富,等.实时电价条件下基于用户引导的电动汽车-充电桩匹配策略[J]. 电力系统自动化,2020,44(8):74-82.
 - LI Dongdong, DUAN Weiyi, LIN Shunfu, et al. User guidance based matching strategy for electric vehicle-charging pile in condition of real-time electricity price[J]. Automation of Electric Power Systems, 2020, 44(8): 74-82(in Chinese).
- [26] 杨晓东,张有兵,蒋杨昌,等.微电网下考虑分布式电源消纳的电动汽车互动响应控制策略[J]. 电工技术学报,2018,33(2):390-400.
 - YANG Xiaodong, ZHANG Youbing, JIANG Yangchang, et al. Renewable Energy accommodation-based strategy for electric vehicle considering dynamic interaction in microgrid[J]. Transactions of China Electrotechnical Society, 2018, 33(2): 390-400(in Chinese).
- [27] SCHIBUOLA L, SCARPA M, TAMBANI C. Demand response management by means of heat pumps controlled via real time pricing[J]. Energy and Buildings, 2015, 90: 15-28.
- [28] 杨晓东,张有兵,翁国庆,等.基于虚拟电价的电动汽车充放电优化调度及其实现机制研究[J]. 电工技术学报,2016,31(17):52-62.
 - YANG Xiaodong, ZHANG Youbing, WENG Guoqing, et al. Virtual time-of-use tariffs based optimal scheduling and implementation mechanism of electric vehicles charging and discharging[J]. Transactions of China Electrotechnical Society, 2016, 31(17): 52-62(in Chinese).
- [29] 董海鹰, 贠韫韵, 汪宁渤, 等. 基于双重电价的电动汽车充放电两阶段优化调度策略[J]. 太阳能学报, 2021, 42(4): 115-124.

DONG Haiying, YUN Yunyun, WANG Ningbo, et al. Two-stage dispatch optimization strategy for charging and discharging of electric vehicles based on double electricity price[J]. Acta Energiae Solaris Sinica, 2021, 42(4): 115-124(in Chinese).

[30] 赵玉,徐天奇,李琰,等.基于分时电价的电动汽车调度策略研究[J].电力系统保护与控制,2020,48(11):92-101.

ZHAO Yu, XU Tianqi, LI Yan, et al. Research on electric vehicle scheduling strategy based on time-shared electricity price[J]. Power System Protection and Control, 2020, 48(11): 92-101(in Chinese).

[31] 麻秀范,王超,洪潇,等.基于实时电价的电动汽车充放电优化策略和经济调度模型[J].电工技术学报,2016,31(S1):190-202.

MA Xiufan, WANG Chao, HONG Xiao, et al. Optimal scheduling of charging and discharging of electric vehicle based on real time price and economic dispatch model[J]. Transactions of China Electrotechnical Society, 2016, 31(S1): 190-202(in Chinese).

[32] NEUBAUER J, WOOD E. The impact of range anxiety and home, workplace, and public charging infrastructure on simulated battery electric vehicle lifetime utility[J]. Journal of Power Sources, 2014, 257(3): 12-20.

附录 A 高斯拟合推导过程:

根据概率论原理,一个服从一维高斯混合分布的数组 $X=\{x_1,x_2,\cdots,x_3\}$,其概率密度函数可以表示为

$$\begin{cases} f_{k}(x | \theta_{k}) = \frac{1}{\sqrt{2\pi\sigma_{k}^{2}}} e^{-\left[\frac{(x-\mu_{k})^{2}}{2\sigma_{k}^{2}}\right]} \\ p(x | \Theta) = \sum_{k=1}^{M} \varphi_{k} f_{k}(x | \theta_{k}) \end{cases}$$
(A1)

式中: $f_k(x|\theta_k)$ 为第 k 个单个高斯分布的 PDF; Θ = $(\varphi_1, \varphi_2, \dots, \varphi_M, \theta_1, \theta_2, \dots, \theta_M)$ 表示高斯混合分布由 M 个单高斯分布构成; θ_k 为第 k 个单高斯分布的均值和标准差 (μ_k, σ_k) ; φ_k 为第 k 个单高斯分布的权值,满足:

$$\sum_{k=1}^{M} \varphi_k = 1 \tag{A2}$$

根据贝叶斯理论,第i个样本数据 x_i 由第k个高斯分布生成的概率为

$$p(k \mid x_i, \Theta^{(t)}) = \frac{p(k, x_i \mid \Theta_k^{(t)})}{p(x_i \mid \Theta^{(t)})} = \frac{\varphi_k p_k(x_i \mid \Theta_k^{(t)})}{\sum_{i=1}^{M} \varphi_i p_i(x_i \mid \Theta_i^{(t)})}$$
(A3)

式中: $\Theta^{(t)}$ 为第 t 次迭代开始时的估计值 Θ ; 每个高斯分布的分布参数为 $\Theta_t^{(t+1)} = (\varphi_t^{(t+1)}, \mu_t^{(t+1)}, \sigma_t^{(t+1)})$, 其计算方法为:

$$\begin{cases} \varphi_k^{(t+1)} = \frac{\sum_{i=1}^{N} p(k \mid x_i, \Theta^{(t)})}{N} \\ \mu_k^{(t+1)} = \frac{\sum_{i=1}^{N} [x_i p(k \mid x_i, \Theta^{(t)})]}{\sum_{i=1}^{N} p(k \mid x_i, \Theta^{(t)})}, \forall k \in \{1, 2, \dots, M\} \\ (\sigma_k^2)^{(t+1)} = \frac{\sum_{i=1}^{N} [(x_i - \mu_k)^2 p(k \mid x_i, \Theta^{(t)})]}{\sum_{i=1}^{N} p(k \mid x_i, \Theta^{(t)})} \end{cases}$$
(A4)

迭代结束的条件为两次迭代之间的分布参数之差小于 误差阈值 ε ,即:

$$\max(|\mathcal{O}_{k}^{(t+1)} - \mathcal{O}_{k}^{(t)}|) < \varepsilon, \forall k \in \{1, 2, \dots, M\}$$
 (A5)

表 A1 拟合分布参数
Table A1 Fitting distribution parameters

参数	H-W	W-H
a_1	0.1849	0.3225
b_1	30.36	67.64
c_1	3.497	5.303
a_2	0.1494	-0.1881
b_2	29.59	66.79
c_2	7.92	3.523
a_3	0.02414	0.05372
b_3	53.84	67.8
c_3	16.33	22.47
a_4	_	-0.008854
b_4	_	83.68
c_4		2.33



张良

在线出版日期: 2021-11-05。 收稿日期: 2021-05-31。 作者简介:

张良(1985),男,博士,副教授,主要研究方向为 V2G 信息交互、多能源微电网优化控制、配电网信息系统等, riescharchit@162.com

xiaozhanghit@163.com;

*通信作者: 孙成龙(1996), 男, 硕士研究生,主要研究方向为电动汽车有序充放电优化, scl3723@163.com。

(责任编辑 李泽荣)

Two-stage Optimization Strategy for Coordinated Charging and Discharging of EVs Based on PSO Algorithm

ZHANG Liang, SUN Chenglong*, CAI Guowei, HUANG Nantian, LYU Ling

(Key Laboratory of Modern Power System Simulation and Control & Renewable Energy Technology, Ministry of Education (Northeast Electric Power University))

KEY WORDS: electric vehicle; coordinated charging and discharging; optimization strategy; PSO algorithm

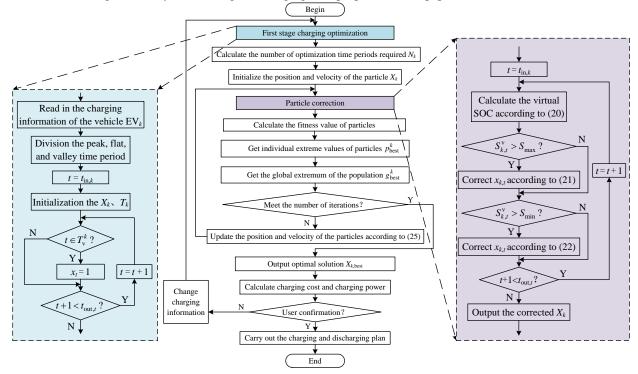
Due to the large randomness and uncertainty of the charging behavior of EV users, large-scale EV access to the grid will increase the difficulty of controlling the grid. Therefore, it is necessary to formulate effective charging optimization strategies for EVs to reduce the aforementioned adverse effects and promote the long-term development of the EV industry. However, both the traditional time-of-use tariff (TOUT) and the real-time price (RTP) demand response mechanism will generate new load peaks during the low load period. To solve this problem, considering the demand for peak load regulating on the grid side and the different needs and willingness of different users for charging capacity and charging costs, a dynamic optimization method for TOUT is proposed, as shown in Fig. 1.

In this paper, particle swarm optimization (PSO) is used to optimize the charging (discharging) behavior of each EV in two stages. And by introducing the charging and discharging control coefficient $x_{k,t}$ and virtual state of charge $S_{k,t}^{v}$ the optimized charging (discharging) behavior can be modified, as shown in (1).

$$S_{k,t}^{v} = S_{k,t-1}^{v} + x_{k,t} \frac{P_k}{C_k} \times \frac{1}{4}$$
 (1)

Where $S_{k,t-1}$ is the actual SOC in the previous period; P_k is the charging and discharging power of the vehicle EV_k; C_k is the battery capacity of the EV_k.

Through simulation experiments, the feasibility of the proposed optimization strategy is verified, and the results show that compared with TOUT and RTP, the proposed strategy effectively reduces the user's charging cost and load curve fluctuations. In addition, under the background that V2G technology has not yet been fully popularized, it is more practical to control the peak shaving effect of EV by controlling the optimization weight of the orderly charging and discharging strategy proposed in this paper.



 $Fig.\ 1\quad Two-stage\ optimization\ process\ of\ charging\ and\ discharging$